

Московский государственный университет имени М. В. Ломоносова
механико-математический факультет
кафедра математической теории интеллектуальных систем

Курсовая работа

студента 531 группы
Мирошниченко Никиты Игоревича

Проекторно-нормированные ранго-сохраняющие методы
для низкоранговой матричной оптимизации

Projector-normalized rank-preserving methods
for low-rank matrix optimization

Научный руководитель:
м.н.с., к.ф.-м.н.
Иванов Илья Евгеньевич

Москва, 2026

Аннотация

В работе рассматриваются методы оптимизации по множеству матриц фиксированного ранга. Исходной точкой является экспоненциальный матричный шаг, возникающий как предел фиктивной многофакторной параметризации. Показано, что односторонний вариант сохраняет ядро матрицы, а двусторонний вариант, хотя и снимает это ограничение, обладает неблагоприятным спектральным масштабированием через квадраты сингулярных значений. Для устранения этого дефекта предлагается проекторно-нормированное направление, в котором матрицы Грама заменяются ортогональными проекторами на левые и правые сингулярные подпространства. На его основе строятся две схемы: эйлерова проекторная и экспоненциальная ранго-сохраняющая. Численные эксперименты на задачах matrix completion и image inpainting показывают, что нормированное направление существенно улучшает поведение исходных экспоненциальных схем.

Содержание

1	Введение	3
2	Исходные экспоненциальные схемы и их ограничения	4
2.1	Фиктивная многофакторная параметризация	4
2.2	Левый односторонний экспоненциальный шаг	7
2.3	Правый односторонний экспоненциальный шаг	8
2.4	Двусторонний экспоненциальный шаг	9
3	Проекторно-нормированное направление и две схемы	10
3.1	Нормированное направление	10
3.2	Непрерывный нормированный поток	11
3.3	Эйлерова проекторная схема	12
3.4	Нормированная экспоненциальная схема	13
3.5	Краткое сравнение с касательным направлением	14
3.6	Вычислительная реализация предлагаемых схем	14
4	Методы сравнения	15
4.1	SVP	15
4.2	Факторный градиентный спуск	15
4.3	ScaledGD	15
4.4	Riemannian-GD	16
4.5	Nuclear-Prox	16
4.6	Сравнение внутри предлагаемого подхода	16
5	Экспериментальная постановка	17
5.1	Matrix completion	17
5.2	Image inpainting	17
5.3	Серии экспериментов	17
5.4	Детали экспериментальной реализации	18

6	Результаты	18
6.1	Один запуск matrix completion	19
6.2	Multi-seed проверка	20
6.3	Sweep по доле наблюдений	21
6.4	Sweep по condition number	22
6.5	Rank mismatch	23
6.6	Сравнение нормированных схем	24
6.7	Runtime и масштабируемость	24
7	Обсуждение результатов	25
8	Заключение	26
8.1	Планы на будущее	27

1 Введение

Низкоранговые матричные модели возникают во многих задачах машинного обучения и численной математики: восстановление матриц по неполным наблюдениям, рекомендательные системы, сжатие изображений, пониженная размерность в многозадачной регрессии, матричное восстановление по линейным измерениям. Во всех этих задачах естественно возникает оптимизационная постановка вида

$$\min_{A \in \mathbb{R}^{m \times n}, \text{rank } A=r} L(A), \quad (1)$$

где L — гладкий функционал потерь, а $r \ll \min(m, n)$ — заданный ранг приближения.

Классический способ учитывать ограничение ранга состоит в использовании проекции на множество матриц ранга r . Например, можно выполнить обычный градиентный шаг $A \leftarrow A - \eta \nabla L(A)$, после чего заменить полученную матрицу её лучшим приближением ранга r по сингулярному разложению. Такой подход лежит в основе метода SVP (Singular Value Projection). Другой распространённый подход состоит в факторизации

$$A = UV^\top, \quad U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}, \quad (2)$$

и последующей оптимизации по факторам U и V .

В данной работе рассматривается другой подход. Вместо того чтобы начинать с факторизации $A = UV^\top$, мы строим обновления непосредственно для матрицы A . Первоначальная идея возникает из экспоненциальных матричных шагов вида

$$A_+ = \exp(-\eta \nabla L(A) A^\top) A. \quad (3)$$

Поскольку матричная экспонента обратима, такое обновление сохраняет ранг матрицы. Однако у этого шага есть существенный недостаток: он имеет вид $A_+ = Q A$ и, следовательно, сохраняет не только ранг, но и ядро матрицы. Для задач восстановления низкоранговой структуры это ограничение часто оказывается слишком жёстким.

Главная идея данной курсовой работы состоит в построении нормированного направления

$$D(A) = \nabla L(A) P_V + P_U \nabla L(A), \quad P_U = A A^+, \quad P_V = A^+ A, \quad (4)$$

где A^+ — псевдообратная матрица Мура–Пенроуза. Это направление заменяет плохое масштабирование через матрицы Грама $A^\top A$ и $A A^\top$ на проекторы на левые и правые сингулярные подпространства.

На основе направления (4) в работе рассматриваются две схемы. Первая схема — эйлерова проекторная версия:

$$A_{k+1} = \mathcal{P}_r(A_k - \eta D(A_k)), \quad (5)$$

где $\mathcal{P}_r$ обозначает проекцию на множество матриц ранга r .

Вторая схема — экспоненциальная версия:

$$A_{k+1} = \exp(-\eta \nabla L(A_k) A_k^+) A_k \exp(-\eta A_k^+ \nabla L(A_k)). \quad (6)$$

Она имеет тот же первый порядок по η , но сохраняет ранг структурно, без явной SVD-проекции после шага.

Цель данной курсовой работы — вывести исходный экспоненциальный шаг из фиктивной факторизации, объяснить его ограничения, предложить нормированное направление (4), а также исследовать две индуцированные им схемы: эйлерову проекторную и экспоненциальную ранго-сохраняющую.

Основные элементы работы состоят в следующем:

- 1) исходный односторонний экспоненциальный шаг выводится как предел обучения фиктивной многофакторной параметризации;
- 2) показывается, что двусторонний экспоненциальный шаг сохраняет ранг, но в первом порядке содержит нежелательные множители Σ^2 ;
- 3) предлагается проекторно-нормированное направление, соответствующее замене Σ^2 на единичную матрицу в активных сингулярных подпространствах;
- 4) строятся две схемы с одинаковым первым порядком: проекторная схема Эйлера и экспоненциальная ранго-сохраняющая схема;
- 5) проводится экспериментальное сравнение с SVP, ScaledGD, Riemannian-GD и другими базовыми методами.

Работа устроена следующим образом. В разделе 2 выводится исходный экспоненциальный шаг как предел фиктивной многофакторной параметризации и обсуждаются ограничения полученной схемы. В разделе 3 вводится проекторно-нормированное направление и две схемы на его основе. В разделе 4 описываются методы, с которыми проводится сравнение. В разделе 5 формулируются экспериментальные задачи. В разделе 6 приводятся численные результаты. В разделе 7 обсуждаются полученные результаты и ограничения метода. Основные выводы и дальнейшие направления исследования содержатся в разделе 8.

2 Исходные экспоненциальные схемы и их ограничения

Пусть $L : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ — гладкий функционал, а

$$G = \nabla L(A) \tag{7}$$

— его евклидов градиент в точке A относительно скалярного произведения Фробениуса

$$\langle X, Y \rangle_F = \text{tr}(XY^\top). \tag{8}$$

2.1 Фиктивная многофакторная параметризация

Перед тем как вводить экспоненциальный шаг, объясним, откуда он возникает. Идея состоит в следующем: исходную матрицу $A \in \mathbb{R}^{m \times n}$ будем рассматривать как результат произведения большого числа фиктивных матриц. При этом сами эти матрицы не предполагается хранить или использовать в реальном алгоритме. Они нужны только для вывода индуцированного обновления на эффективной матрице A .

Пусть $N \geq 2$. Рассмотрим фиктивную параметризацию

$$\mathcal{A}(P_1, \dots, P_{N-1}, B) = P_{N-1}P_{N-2} \cdots P_1 B, \quad (9)$$

где

$$P_i \in \mathbb{R}^{m \times m}, \quad B \in \mathbb{R}^{m \times n}. \quad (10)$$

Текущей матрице A соответствует специальная точка параметрического пространства

$$P_1 = P_2 = \cdots = P_{N-1} = I_m, \quad B = A. \quad (11)$$

Тогда

$$\mathcal{A}(I_m, \dots, I_m, A) = A. \quad (12)$$

Рассмотрим функционал

$$\tilde{L}(P_1, \dots, P_{N-1}, B) = L(\mathcal{A}(P_1, \dots, P_{N-1}, B)). \quad (13)$$

Пусть

$$G = \nabla L(A). \quad (14)$$

Найдём градиенты функционала $\tilde{L}$ по фиктивным параметрам в точке

$$(P_1, \dots, P_{N-1}, B) = (I_m, \dots, I_m, A). \quad (15)$$

Сначала рассмотрим вариацию по матрице B . Если B заменить на $B + \varepsilon H$, то в указанной точке

$$\delta \mathcal{A} = H. \quad (16)$$

Следовательно,

$$D_B \tilde{L}[H] = \langle G, H \rangle_F. \quad (17)$$

Значит,

$$\nabla_B \tilde{L} = G. \quad (18)$$

Теперь рассмотрим вариацию по одному из фиктивных левых множителей P_i . Пусть P_i заменяется на $P_i + \varepsilon H$. Поскольку все остальные множители равны единичной матрице, вариация эффективной матрицы равна

$$\delta \mathcal{A} = H A. \quad (19)$$

Поэтому

$$D_{P_i} \tilde{L}[H] = \langle G, H A \rangle_F. \quad (20)$$

Используя определение скалярного произведения Фробениуса, получаем

$$\langle G, H A \rangle_F = \text{tr} (G (H A)^\top) \quad (21)$$

$$= \text{tr} (G A^\top H^\top) \quad (22)$$

$$= \langle G A^\top, H \rangle_F. \quad (23)$$

Следовательно,

$$\nabla_{P_i} \tilde{L} = G A^\top, \quad i = 1, \dots, N-1. \quad (24)$$

Таким образом, в начальной точке все фиктивные квадратные множители имеют один и тот же градиент

$$X := GA^\top \in \mathbb{R}^{m \times m}. \quad (25)$$

Теперь выполним один шаг градиентного спуска по всем фиктивным параметрам. Важный момент состоит в том, что шаг по каждому фиктивному множителю масштабируется как

$$h_N = \frac{\eta}{N-1}. \quad (26)$$

Тогда

$$P_i^+ = I_m - h_N GA^\top = I_m - h_N X, \quad i = 1, \dots, N-1, \quad (27)$$

а для последнего множителя

$$B^+ = A - h_N G. \quad (28)$$

Эффективная матрица после такого фиктивного шага равна

$$A_N^+ = (I_m - h_N X)^{N-1} (A - h_N G). \quad (29)$$

Именно формула (29) является дискретным обновлением матрицы A , индуцированным обучением фиктивной многофакторной модели.

Теорема 1. Пусть $A, G \in \mathbb{R}^{m \times n}$ фиксированы, $X = GA^\top$ и $\eta > 0$. Тогда при $N \rightarrow \infty$ выполнено

$$A_N^+ = \left(I_m - \frac{\eta}{N-1} X \right)^{N-1} \left(A - \frac{\eta}{N-1} G \right) \longrightarrow \exp(-\eta X) A. \quad (30)$$

Иными словами,

$$A_N^+ \longrightarrow \exp(-\eta GA^\top) A. \quad (31)$$

Доказательство. Положим

$$h_N = \frac{\eta}{N-1}. \quad (32)$$

Тогда

$$A_N^+ = (I_m - h_N X)^{N-1} (A - h_N G). \quad (33)$$

Вычтем предполагаемый предел:

$$A_N^+ - e^{-\eta X} A = ((I_m - h_N X)^{N-1} - e^{-\eta X}) A - (I_m - h_N X)^{N-1} h_N G. \quad (34)$$

Рассмотрим первый член. По стандартному свойству матричной экспоненты

$$\left(I_m - \frac{\eta}{N-1} X \right)^{N-1} \longrightarrow e^{-\eta X}. \quad (35)$$

Следовательно,

$$((I_m - h_N X)^{N-1} - e^{-\eta X}) A \longrightarrow 0. \quad (36)$$

Остаётся рассмотреть второй член в (34). Последовательность

$$(I_m - h_N X)^{N-1} \quad (37)$$

сходится к $e^{-\eta X}$, а значит, ограничена в любой фиксированной матричной норме. Так как

$$h_N G \longrightarrow 0, \quad (38)$$

то

$$(I_m - h_N X)^{N-1} h_N G \longrightarrow 0. \quad (39)$$

Из (34) получаем

$$A_N^+ \longrightarrow e^{-\eta X} A = e^{-\eta G A^\top} A. \quad (40)$$

□

Теорема 1 показывает, что односторонний экспоненциальный шаг не является произвольной эвристикой. Он возникает как предел обучения фиктивной модели, в которой текущая матрица A представляется произведением всё большего числа фиктивных множителей. Масштабирование шага как $\eta/(N-1)$ приводит к тому, что совокупное действие большого числа малых градиентных обновлений превращается в матричную экспоненту.

Таким образом, естественным предельным обновлением эффективной матрицы становится

$$A_+ = \exp(-\eta \nabla L(A) A^\top) A. \quad (41)$$

Важно подчеркнуть, что фиктивная факторизация используется только для вывода формулы. В практическом алгоритме не требуется хранить матрицы

$$P_1, \dots, P_{N-1}. \quad (42)$$

После перехода к пределу объектом исследования становится непосредственно отображение (41).

2.2 Левый односторонний экспоненциальный шаг

В соответствии с предельной формулой (41) рассмотрим отображение

$$\Phi_\eta(A) = \exp(-\eta G A^\top) A. \quad (43)$$

Оно является естественным матричным аналогом градиентного шага, но действие градиента происходит не аддитивно, а через левое умножение на обратимую матрицу.

Предложение 1. Для любого $\eta \geq 0$ отображение (43) сохраняет ранг и ядро матрицы:

$$\text{rank } \Phi_\eta(A) = \text{rank } A, \quad \text{Ker } \Phi_\eta(A) = \text{Ker } A. \quad (44)$$

Доказательство. Обозначим

$$Q = \exp(-\eta G A^\top). \quad (45)$$

Матрица Q обратима, поскольку любая матричная экспонента обратима. Тогда

$$\Phi_\eta(A) = Q A. \quad (46)$$

Следовательно, для любого $x \in \mathbb{R}^n$ имеем

$$\Phi_\eta(A)x = 0 \iff QAx = 0 \iff Ax = 0. \quad (47)$$

Значит, ядро сохраняется. Из равенства ядер следует сохранение ранга по теореме о ранге и дефекте. □

Таким образом, односторонний шаг действительно сохраняет ранг. Однако сохранение ядра оказывается нежелательным в задачах восстановления низкоранговой матрицы. Если начальное правое подпространство выбрано неточно, метод не может свободно его изменить.

2.3 Правый односторонний экспоненциальный шаг

После анализа левого одностороннего шага возникает естественный вопрос: можно ли умножать матрицу не слева, а справа? Рассмотрим правое экспоненциальное обновление

$$A_+ = A \exp(-\eta A^\top G), \quad G = \nabla L(A). \quad (48)$$

Обозначим

$$P = \exp(-\eta A^\top G).$$

Матрица P обратима, поэтому шаг имеет вид $A_+ = AP$ и сохраняет ранг. Однако теперь возникает другое ограничение: сохраняется не ядро, а образ матрицы.

Здесь под образом матрицы понимается множество всех возможных значений линейного оператора A :

$$\text{Im}(A) = \{Ax : x \in \mathbb{R}^n\}.$$

Иначе говоря, это линейная оболочка столбцов матрицы A .

Предложение 2. Для любого $\eta \geq 0$ правый односторонний шаг (48) сохраняет ранг и образ матрицы:

$$\text{rank } A_+ = \text{rank } A, \quad \text{Im}(A_+) = \text{Im}(A).$$

Доказательство. Так как $A_+ = AP$, где P обратима, умножение справа на P не меняет ранг. Докажем сохранение образа. Для любого x имеем

$$A_+x = APx = A(Px),$$

поэтому A_+x является значением оператора A . Значит,

$$\text{Im}(A_+) \subseteq \text{Im}(A).$$

С другой стороны, поскольку P обратима,

$$A = A_+P^{-1}.$$

Следовательно, каждый вектор вида Ax можно записать как

$$Ax = A_+P^{-1}x,$$

то есть он принадлежит $\text{Im}(A_+)$. Поэтому

$$\text{Im}(A) \subseteq \text{Im}(A_+).$$

Из двух включений получаем равенство образов. □

Пусть теперь $A = U\Sigma V^\top$ — тонкое SVD-разложение. Под этим понимается разложение матрицы ранга r , в котором оставлены только ненулевые сингулярные значения:

$$U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_r),$$

$$U^\top U = I_r, \quad V^\top V = I_r, \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

В отличие от полного SVD, в тонком SVD не выписываются направления, соответствующие нулевым сингулярным значениям. Поэтому матрица Σ обратима. Образ матрицы A совпадает с линейной оболочкой столбцов U :

$$\text{Im}(A) = \text{span}(U).$$

Здесь, если $U = (u_1, \dots, u_r)$, то

$$\text{span}(U) = \{\alpha_1 u_1 + \dots + \alpha_r u_r : \alpha_1, \dots, \alpha_r \in \mathbb{R}\}.$$

Действительно, для любого x выполнено

$$Ax = U\Sigma V^\top x,$$

то есть Ax является линейной комбинацией столбцов U . Обратное включение следует из обратимости Σ : если $y = Uz$, то при $x = V\Sigma^{-1}z$ имеем

$$Ax = U\Sigma V^\top V\Sigma^{-1}z = Uz = y.$$

Таким образом, сохранение образа означает сохранение левого сингулярного подпространства. Поэтому правый односторонний шаг является зеркальным аналогом левого: левый шаг фиксирует правое подпространство, а правый шаг фиксирует левое подпространство. В задачах восстановления низкоранговой матрицы обычно нужно менять оба подпространства, поэтому дальше естественно перейти к двустороннему обновлению.

Разложение правого шага по η даёт

$$A \exp(-\eta A^\top G) = A(I - \eta A^\top G) + O(\eta^2) \tag{49}$$

$$= A - \eta AA^\top G + O(\eta^2). \tag{50}$$

Если $A = U\Sigma V^\top$, то $AA^\top = U\Sigma^2 U^\top$. Поэтому первый порядок правого шага также содержит плохое спектральное масштабирование через квадраты сингулярных значений.

2.4 Двусторонний экспоненциальный шаг

Поскольку левый односторонний шаг фиксирует правое подпространство, а правый односторонний шаг фиксирует левое подпространство, рассмотрим двустороннюю схему

$$\Psi_\eta(A) = \exp(-\eta GA^\top) A \exp(-\eta A^\top G). \tag{51}$$

Теперь обновление имеет вид

$$A_+ = QAP, \tag{52}$$

где Q и P обратимы. Поэтому ранг сохраняется, но ядро уже не обязано оставаться тем же самым.

Разложим (51) по η :

$$\Psi_\eta(A) = (I - \eta G A^\top) A (I - \eta A^\top G) + O(\eta^2) \quad (53)$$

$$= A - \eta (G A^\top A + A A^\top G) + O(\eta^2). \quad (54)$$

Соответствующий непрерывный предел имеет вид

$$\dot{A} = -G A^\top A - A A^\top G. \quad (55)$$

У этой схемы есть существенный спектральный недостаток. Пусть

$$A = U \Sigma V^\top \quad (56)$$

— тонкое сингулярное разложение матрицы A ранга r в указанном выше смысле. Тогда

$$A^\top A = V \Sigma^2 V^\top, \quad A A^\top = U \Sigma^2 U^\top. \quad (57)$$

Следовательно, направление (55) масштабируется через квадраты сингулярных значений. Если матрица плохо обусловлена, то малые сингулярные направления обновляются существенно медленнее крупных. Именно это приводит к замедлению и выходу на плато в численных экспериментах.

3 Проекторно-нормированное направление и две схемы

3.1 Нормированное направление

Главный недостаток двустороннего экспоненциального шага состоит в том, что его первый порядок содержит направление

$$D_{\text{old}}(A) = G A^\top A + A A^\top G. \quad (58)$$

Пусть $A = U \Sigma V^\top$ — тонкое SVD-разложение матрицы A ранга r в указанном выше смысле. Тогда

$$A^\top A = V \Sigma^2 V^\top, \quad A A^\top = U \Sigma^2 U^\top, \quad (59)$$

и поэтому

$$D_{\text{old}}(A) = G V \Sigma^2 V^\top + U \Sigma^2 U^\top G. \quad (60)$$

Эта формула показывает, что матрицы $A^\top A$ и $A A^\top$ выполняют две разные роли. С одной стороны, они выделяют правое и левое сингулярные подпространства матрицы A . С другой стороны, они дополнительно масштабируют соответствующие компоненты градиента квадратами сингулярных значений. Именно вторая роль нежелательна: если матрица плохо обусловлена, то направления, связанные с малыми сингулярными значениями, обновляются существенно медленнее.

Поэтому естественная нормировка состоит в том, чтобы сохранить только подпространственную часть действия $A^\top A$ и $A A^\top$, но удалить спектральные веса Σ^2 . Иными словами, в первом порядке старого направления мы заменяем

$$V \Sigma^2 V^\top \mapsto V V^\top, \quad U \Sigma^2 U^\top \mapsto U U^\top. \quad (61)$$

Так получается направление

$$GVV^\top + UU^\top G. \quad (62)$$

Чтобы записать его без явного указания SVD, используем псевдообратную матрицу Мура–Пенроуза. Если

$$A = U\Sigma V^\top, \quad U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}, \quad (63)$$

где $U^\top U = I_r$, $V^\top V = I_r$, а Σ обратима, то

$$A^+ = V\Sigma^{-1}U^\top. \quad (64)$$

Следовательно,

$$P_U = AA^+ = UU^\top, \quad P_V = A^+A = VV^\top. \quad (65)$$

Доказательство. Проверим эти равенства напрямую. Так как $U^\top U = I_r$ и $V^\top V = I_r$, имеем

$$AA^+ = U\Sigma V^\top V\Sigma^{-1}U^\top = U\Sigma\Sigma^{-1}U^\top = UU^\top, \quad (66)$$

$$A^+A = V\Sigma^{-1}U^\top U\Sigma V^\top = V\Sigma^{-1}\Sigma V^\top = VV^\top. \quad (67)$$

Матрицы $UU^\top$ и $VV^\top$ являются ортогональными проекторами. Напомним, что матрица P называется идемпотентной, если $P^2 = P$. Для $UU^\top$ имеем симметричность и идемпотентность:

$$(UU^\top)^\top = UU^\top, \quad (UU^\top)^2 = U(U^\top U)U^\top = UU^\top,$$

и аналогично для $VV^\top$. □

Именно в этом смысле замена $A^\top$ на A^+ нормирует старое экспоненциальное направление: вместо грамовых матриц с весами Σ^2 появляются ортогональные проекторы на те же сингулярные подпространства.

Определение 1. *Пректорно-нормированным направлением будем называть матрицу*

$$D(A) = GP_V + P_U G, \quad G = \nabla L(A). \quad (68)$$

Это направление зависит от текущих левого и правого подпространств матрицы A , но не содержит множителей Σ^2 . Поэтому оно не подавляет искусственно направления, связанные с малыми сингулярными значениями.

3.2 Непрерывный нормированный поток

С направлением (68) связан непрерывный поток

$$\dot{A} = -D(A) = -GP_V - P_U G. \quad (69)$$

Теорема 2. *Пусть $L \in C^1(\mathbb{R}^{m \times n})$, $G = \nabla L(A)$, и пусть $A(t)$ удовлетворяет уравнению (69). Тогда*

$$\frac{d}{dt}L(A(t)) = -\|GV\|_F^2 - \|U^\top G\|_F^2 \leq 0, \quad (70)$$

где $A = U\Sigma V^\top$.

Доказательство. По правилу цепочки

$$\frac{d}{dt}L(A(t)) = \left\langle G, \dot{A} \right\rangle_F. \quad (71)$$

Подставляя (69), получаем

$$\left\langle G, \dot{A} \right\rangle_F = -\langle G, GP_V \rangle_F - \langle G, P_U G \rangle_F. \quad (72)$$

Так как $P_V = VV^\top$ и $P_U = UU^\top$, имеем

$$\langle G, GP_V \rangle_F = \text{tr}(GP_V G^\top) = \text{tr}(GVV^\top G^\top) = \|GV\|_F^2, \quad (73)$$

а также

$$\langle G, P_U G \rangle_F = \text{tr}(GG^\top P_U) = \text{tr}(U^\top GG^\top U) = \|U^\top G\|_F^2. \quad (74)$$

Следовательно,

$$\frac{d}{dt}L(A(t)) = -\|GV\|_F^2 - \|U^\top G\|_F^2 \leq 0. \quad (75)$$

□

Таким образом, нормированный поток является спускающим потоком для функционала L . Это является теоретическим обоснованием для построения дискретных методов на основе направления (68).

3.3 Эйлерова проекторная схема

Нормированный поток имеет вид

$$\dot{A} = -D(A).$$

Чтобы получить из него итерационный алгоритм, нужно заменить непрерывное время дискретными шагами. Самая простая дискретизация дифференциального уравнения $\dot{x} = f(x)$ — явная схема Эйлера:

$$x_{k+1} = x_k + \eta f(x_k).$$

Она получается из разложения

$$x(t + \eta) = x(t) + \eta \dot{x}(t) + O(\eta^2)$$

оставлением только линейного по η члена. Поэтому для потока $\dot{A} = -D(A)$ эйлеров шаг имеет вид

$$A_k - \eta D(A_k).$$

Такой шаг сам по себе не обязан сохранять ранг, поэтому после него применяется усечение SVD до ранга r .

Определение 2. Эйлеровой нормированной схемой будем называть метод

$$A_{k+1} = \mathcal{P}_r(A_k - \eta(G_k P_{V,k} + P_{U,k} G_k)), \quad (76)$$

где

$$G_k = \nabla L(A_k), \quad P_{U,k} = A_k A_k^+, \quad P_{V,k} = A_k^+ A_k.$$

Здесь $\mathcal{P}_r$ обозначает усечение SVD до ранга r .

Если $B = \sum_i \sigma_i u_i v_i^\top$ — SVD-разложение матрицы B с $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$, то

$$\mathcal{P}_r(B) = \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

По теореме Эккарта–Янга–Мирского эта матрица является ближайшей к B матрицей ранга не выше r в норме Фробениуса.

Пусть на текущей итерации известно тонкое SVD-разложение

$$A_k = U_k \Sigma_k V_k^\top.$$

Тогда

$$P_{U,k} = U_k U_k^\top, \quad P_{V,k} = V_k V_k^\top.$$

Следовательно, нормированное направление можно записать как

$$D(A_k) = G_k V_k V_k^\top + U_k U_k^\top G_k. \quad (77)$$

На практике полные проекторы $U_k U_k^\top$ и $V_k V_k^\top$ строить не нужно. Достаточно один раз свернуть множители по ассоциативности матричного умножения:

$$G_k (V_k V_k^\top) = (G_k V_k) V_k^\top, \quad (U_k U_k^\top) G_k = U_k (U_k^\top G_k).$$

Поэтому вычисление одного эйлерова шага устроено так:

$$\begin{aligned} D_k &= (G_k V_k) V_k^\top + U_k (U_k^\top G_k), \\ B_k &= A_k - \eta D_k, \quad A_{k+1} = \mathcal{P}_r(B_k). \end{aligned}$$

Именно в этом смысле в эйлеровой схеме не требуется явно формировать псевдообратную матрицу A_k^+ : нужны только базисы U_k и V_k , которые возникают при усечённом SVD.

3.4 Нормированная экспоненциальная схема

Второй способ построить дискретный метод с тем же первым порядком по η состоит в использовании экспоненциального ранго-сохраняющего обновления. В отличие от эйлеровой схемы, здесь матрица обновляется не аддитивно, а умножением слева и справа на обратимые матрицы:

$$\Theta_\eta(A) = \exp(-\eta G A^+) A \exp(-\eta A^+ G), \quad G = \nabla L(A). \quad (78)$$

Теорема 3. Пусть $A \in \mathbb{R}^{m \times n}$ и $\eta \geq 0$. Тогда

$$\text{rank } \Theta_\eta(A) = \text{rank } A. \quad (79)$$

Доказательство. Обозначим

$$Q = \exp(-\eta G A^+), \quad P = \exp(-\eta A^+ G). \quad (80)$$

Матрицы Q и P обратимы. Следовательно,

$$\Theta_\eta(A) = Q A P. \quad (81)$$

Умножение слева и справа на обратимые матрицы не меняет ранг. Значит,

$$\text{rank}(Q A P) = \text{rank } A. \quad (82)$$

□

Разложим (78) по η :

$$\Theta_\eta(A) = (I - \eta GA^+)A(I - \eta A^+G) + O(\eta^2) \quad (83)$$

$$= A - \eta GA^+A - \eta AA^+G + O(\eta^2) \quad (84)$$

$$= A - \eta(GP_V + P_U G) + O(\eta^2). \quad (85)$$

Равенство (85) означает, что при малом шаге η экспоненциальная схема имеет тот же линейный член, что и эйлеров шаг $A - \eta D(A)$. Поэтому она является другой дискретизацией того же нормированного потока. Отличие состоит в том, что ранг сохраняется не с помощью SVD-проекции, а структурно, через умножение слева и справа на обратимые матрицы.

Итак, в работе рассматриваются две разные реализации одной идеи:

1. эйлерова проекторная схема (76);
2. экспоненциальная ранго-сохраняющая схема (78).

Первая схема проще и часто даёт сильные численные результаты. Вторая схема более структурна, поскольку сохраняет ранг без явной проекции после шага.

3.5 Краткое сравнение с касательным направлением

Предлагаемое направление полезно сравнить с направлением, используемым в римановой оптимизации на множестве матриц фиксированного ранга. Если $A = U\Sigma V^\top$, то ортогональная проекция евклидова градиента G на касательное пространство этого множества имеет вид

$$P_T(G) = P_U G + G P_V - P_U G P_V. \quad (86)$$

В данной работе полный вывод этой стандартной формулы не требуется; она используется только для сравнения с известным baseline Riemannian-GD. Важно, что наше направление равно

$$D(A) = P_U G + G P_V = P_T(G) + P_U G P_V. \quad (87)$$

То есть оно похоже на касательное направление, но содержит дополнительный центральный блок $P_U G P_V$.

3.6 Вычислительная реализация предлагаемых схем

В эйлеровой схеме направление вычисляется по формуле, уже полученной в (77). После вычисления D_k выполняется шаг $B_k = A_k - \eta D_k$ и затем усечённое SVD $A_{k+1} = \mathcal{P}_r(B_k)$.

В экспоненциальной схеме требуется больше информации. Если

$$A_k = U_k \Sigma_k V_k^\top,$$

то

$$A_k^+ = V_k \Sigma_k^{-1} U_k^\top,$$

и генераторы экспонент имеют вид

$$G_k A_k^+ = G_k V_k \Sigma_k^{-1} U_k^\top, \quad A_k^+ G_k = V_k \Sigma_k^{-1} U_k^\top G_k.$$

Поэтому для экспоненциальной схемы важны не только подпространства U_k, V_k , но и обратные сингулярные значения. Если некоторые σ_i малы, то элементы Σ_k^{-1} велики, что может приводить к численным трудностям. В данной работе используется наивная реализация с полными матричными экспонентами; более эффективное вычисление экспоненциального действия оставляется как направление дальнейшей работы.

4 Методы сравнения

В экспериментах предлагаемые схемы сравниваются со стандартными методами низкоранговой оптимизации. Здесь приведём только необходимые формулы; подробный вывод этих методов не является целью работы.

4.1 SVP

Метод SVP выполняет обычный градиентный шаг и затем возвращает матрицу к рангу r с помощью усечённого SVD:

$$A_{k+1} = \mathcal{P}_r(A_k - \eta \nabla L(A_k)). \quad (88)$$

Здесь $\mathcal{P}_r$ — оператор лучшего приближения рангом не выше r в норме Фробениуса по теореме Эккарта–Янга–Мирского.

4.2 Факторный градиентный спуск

В факторном подходе матрица представляется в виде

$$A = UV^\top, \quad U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}.$$

Для функции $f(U, V) = L(UV^\top)$ при $G = \nabla L(UV^\top)$ градиенты по факторам равны

$$\nabla_U f = GV, \quad \nabla_V f = G^\top U.$$

Поэтому факторный градиентный спуск использует обновления

$$U_{k+1} = U_k - \eta G_k V_k, \quad V_{k+1} = V_k - \eta G_k^\top U_k.$$

Оба градиента вычисляются в одной и той же точке (U_k, V_k) .

4.3 ScaledGD

ScaledGD является предобусловленной версией факторного градиентного спуска. Его шаги имеют вид

$$U_{k+1} = U_k - \eta (G_k V_k) (V_k^\top V_k + \varepsilon I)^{-1}, \quad (89)$$

$$V_{k+1} = V_k - \eta (G_k^\top U_k) (U_k^\top U_k + \varepsilon I)^{-1}. \quad (90)$$

Малое число $\varepsilon > 0$ добавляется для устойчивости обращения матриц Грама. ScaledGD используется как сильный baseline для задач низкорангового восстановления.

4.4 Riemannian-GD

Riemannian-GD использует касательное направление на множестве матриц фиксированного ранга. Если $A = U\Sigma V^\top$, то стандартная формула касательной проекции градиента имеет вид

$$P_T(G) = P_U G + G P_V - P_U G P_V.$$

После этого выполняется шаг и ретракция через усечённое SVD:

$$A_{k+1} = \mathcal{P}_r(A_k - \eta P_T(G_k)). \quad (91)$$

Этот метод близок к предлагаемой эйлеровой схеме, потому что оба используют проекторы на текущие сингулярные подпространства. Различие состоит в центральном блоке:

$$D(A) = P_U G + G P_V = P_T(G) + P_U G P_V.$$

4.5 Nuclear-Prox

Метод Nuclear-Prox решает не задачу с фиксированным рангом, а регуляризованную задачу

$$\min_A L(A) + \lambda \|A\|_*. \quad (92)$$

Здесь $\|A\|_*$ — ядерная норма, то есть сумма сингулярных значений матрицы:

$$\|A\|_* = \sum_i \sigma_i(A).$$

Проксимальный шаг для ядерной нормы сводится к сингулярному soft-thresholding: если $B = U \operatorname{diag}(\sigma_i) V^\top$, то

$$\operatorname{prox}_{\tau\|\cdot\|_*}(B) = U \operatorname{diag}((\sigma_i - \tau)_+) V^\top, \quad (x)_+ = \max\{x, 0\}.$$

Этот baseline полезен для сравнения, но его нужно интерпретировать отдельно: он не сохраняет заранее заданный ранг, а подбирает его через порогование сингулярных значений.

4.6 Сравнение внутри предлагаемого подхода

Так как в работе предлагается не одна формула, а нормированное направление и две дискретизации на его основе, отдельно сравниваются:

1. исходный двусторонний экспоненциальный метод (51);
2. эйлерова нормированная проекторная схема (76);
3. нормированная экспоненциальная схема (78).

Такое сравнение позволяет понять, какая часть улучшения связана с нормированным направлением, а какая — с экспоненциальной ранго-сохраняющей формой обновления.

5 Экспериментальная постановка

5.1 Matrix completion

Основная экспериментальная задача — восстановление низкоранговой матрицы по части её элементов. Пусть задана матрица

$$M_\star \in \mathbb{R}^{m \times n}, \quad \text{rank } M_\star = r_\star. \quad (93)$$

Наблюдается только часть элементов с индексами из множества Ω . Требуется найти матрицу A ранга r , приближающую $M_\star$.

Обучающий функционал имеет вид

$$L_{\text{train}}(A) = \frac{1}{2|\Omega_{\text{train}}|} \|P_{\Omega_{\text{train}}}(A - M_\star)\|_F^2. \quad (94)$$

Для оценки качества используются следующие метрики.

Observed loss — ошибка на обучающих наблюдаемых элементах:

$$L_{\text{obs}}(A) = \frac{1}{2|\Omega_{\text{train}}|} \|P_{\Omega_{\text{train}}}(A - M_\star)\|_F^2. \quad (95)$$

Validation/test loss — ошибка на отложенных наблюдаемых элементах:

$$L_{\text{test}}(A) = \frac{1}{2|\Omega_{\text{test}}|} \|P_{\Omega_{\text{test}}}(A - M_\star)\|_F^2. \quad (96)$$

Full relative error — относительная ошибка по всей матрице:

$$\text{rel}(A) = \frac{\|A - M_\star\|_F}{\|M_\star\|_F}. \quad (97)$$

В синтетических экспериментах эта величина доступна, так как истинная матрица известна.

5.2 Image inpainting

Задача восстановления изображения рассматривается как частный случай matrix completion. Изображение интерпретируется как матрица яркости пикселей. Часть пикселей скрывается, после чего методы восстанавливают матрицу по наблюдаемым значениям. Эта задача полезна тем, что качество восстановления можно оценивать не только по численным метрикам, но и визуально.

5.3 Серии экспериментов

Для проверки метода проводятся следующие серии экспериментов:

1. один подробный запуск matrix completion;
2. multi-seed проверка на нескольких случайных инициализациях и масках;
3. sweep по доле наблюдаемых элементов;

4. sweep по condition number истинной матрицы;
5. rank mismatch: обучение с рангом, отличным от истинного;
6. сравнение двух предлагаемых нормированных схем;
7. runtime/scalability test;
8. image inpainting.

5.4 Детали экспериментальной реализации

Синтетические эксперименты проводились в режиме, предназначенном для быстрой проверки гипотезы. Если не указано иное, использовались матрицы размера 50×45 с истинным рангом $r_* = 4$ и обучающим рангом $r = 4$. Истинная матрица генерировалась по разложению $M_* = U\Sigma V^\top$, где U и V имеют ортонормированные столбцы, а сингулярные значения выбирались геометрической прогрессией с заданным condition number. В базовом запуске использовались condition number 50, доля наблюдаемых элементов 0.30 и шум с уровнем 10^{-3} .

Для каждого метода параметр шага подбирался по validation loss на коротком прогоне, а затем метод запускался заново с выбранным параметром. В одном подробном запуске использовались 800 итераций и оценка метрик каждые 20 итераций. В multi-seed проверке использовались 5 случайных seed, 600 итераций и короткий прогон для подбора шага длиной 150 итераций. В sweep-экспериментах по доле наблюдений, condition number и рангу использовались по 3 seed на каждую точку сетки.

Для sweep по доле наблюдений рассматривались значения 0.10, 0.20, 0.30 и 0.50. Для sweep по condition number рассматривались значения 1, 10, 100 и 1000. В эксперименте rank mismatch истинный ранг был равен 4, а обучающий ранг принимал значения 2, 3, 4, 6 и 8. В задаче image inpainting использовалось синтетическое изображение размера 64×64 , доля наблюдаемых пикселей 0.35 и обучающий ранг 8.

Все методы сравнивались по test loss и full relative error. В синтетических задачах full relative error доступна, поскольку известна истинная матрица M_* . Для визуальной проверки в задаче image inpainting также сравнивались восстановленные изображения.

6 Результаты

В этом разделе приведены результаты численных экспериментов. Их цель состоит не в том, чтобы показать универсальное превосходство предложенных методов над всеми известными алгоритмами низкоранговой оптимизации, а в проверке основной гипотезы работы: проекторная нормировка исправляет спектральный дефект исходной двусторонней экспоненциальной схемы, связанный с множителями Σ^2 .

Во всех экспериментах основное внимание уделяется сравнению трёх групп методов:

1. исходные экспоненциальные схемы Exp-One-Sided и Exp-Two-Sided;
2. предложенные нормированные схемы Euler-Norm-Two-Sided и Norm-Exp-Two-Sided;

3. классические baseline-методы SVP, Factor-GD, ScaledGD и Riemannian-GD.

Отдельно рассматривается Nuclear-Prox, поскольку этот метод решает задачу с ядерной регуляризацией, а не задачу с фиксированным рангом.

6.1 Один запуск matrix completion

В первом эксперименте сравнивалось качество восстановления матрицы при фиксированной доле наблюдаемых элементов. Основные результаты приведены в таблице 1.

Метод	test loss	full relative error	rank
Euler-Norm-Two-Sided	$1.2 \cdot 10^{-5}$	0.420	4
Riemannian-GD	$1.6 \cdot 10^{-5}$	0.461	4
Norm-Exp-Two-Sided	$3.9 \cdot 10^{-5}$	0.389	4
ScaledGD	$4.3 \cdot 10^{-5}$	0.481	4
Factor-GD	$5.0 \cdot 10^{-5}$	0.719	4
SVP	$5.5 \cdot 10^{-5}$	0.461	4
Exp-Two-Sided	$8.5 \cdot 10^{-5}$	0.632	4
Exp-One-Sided	$1.84 \cdot 10^{-4}$	0.881	4

Таблица 1: Один запуск matrix completion.




Рис. 1: Сходимость методов в одном запуске matrix completion: test loss.




Рис. 2: Сходимость методов в одном запуске matrix completion по full relative error.

В одном запуске обе нормированные схемы улучшают исходные экспоненциальные методы. По test loss лучшим оказался Euler-Norm-Two-Sided, а по full relative error — Norm-Exp-Two-Sided. Это показывает, что нормировка действительно исправляет слабое место исходных экспоненциальных схем. При этом Riemannian-GD, SVP и ScaledGD остаются сильными baseline-методами, поэтому результат следует интерпретировать не как абсолютное превосходство над всеми алгоритмами, а как существенное улучшение исходной экспоненциальной идеи.

6.2 Multi-seed проверка

Для проверки устойчивости эффекта эксперимент был повторён на нескольких случайных инициализациях и масках наблюдений. В таблице 2 приведены средние значения и стандартные отклонения по нескольким seed.

Метод	средний test loss	средний full relative error
SVP	$7.8 \cdot 10^{-5} \pm 4.7 \cdot 10^{-5}$	0.581 ± 0.110
Riemannian-GD	$7.9 \cdot 10^{-5} \pm 5.4 \cdot 10^{-5}$	0.565 ± 0.080
Euler-Norm-Two-Sided	$8.1 \cdot 10^{-5} \pm 4.4 \cdot 10^{-5}$	0.587 ± 0.095
Norm-Exp-Two-Sided	$8.6 \cdot 10^{-5} \pm 4.1 \cdot 10^{-5}$	0.580 ± 0.096
Factor-GD	$8.7 \cdot 10^{-5} \pm 5.5 \cdot 10^{-5}$	0.564 ± 0.130
ScaledGD	$9.0 \cdot 10^{-5} \pm 3.9 \cdot 10^{-5}$	0.607 ± 0.083
Exp-Two-Sided	$2.07 \cdot 10^{-4} \pm 1.42 \cdot 10^{-4}$	0.884 ± 0.249

Таблица 2: Multi-seed проверка на задаче matrix completion.




Рис. 3: Multi-seed проверка: распределение full relative error и test loss по различным seed.

По multi-seed проверке нормированные схемы входят в верхнюю группу методов и существенно превосходят исходный Exp-Two-Sided. Различия между SVP, Riemannian-GD, Euler-Norm-Two-Sided, Norm-Exp-Two-Sided и Factor-GD невелики относительно стандартных отклонений, поэтому этот эксперимент не следует трактовать как доказательство абсолютного превосходства одного метода. Его основной вывод состоит в том, что проекторная нормировка устраняет деградацию старого экспоненциального шага и делает экспоненциальный подход конкурентным с классическими методами.

6.3 Sweep по доле наблюдений

Следующий эксперимент показывает, как качество восстановления зависит от доли наблюдаемых элементов. При очень малой доле наблюдений задача остаётся плохо определённой для всех методов: информации недостаточно для устойчивого восстановления всей матрицы. При увеличении доли наблюдений качество всех алгоритмов улучшается.




Рис. 4: Зависимость full relative error и test loss от доли наблюдаемых элементов.

Нормированные схемы устойчиво улучшают исходный Exp-Two-Sided, однако не во всех режимах превосходят сильные baseline-методы, такие как SVP, Riemannian-GD и ScaledGD. Поэтому основной вывод этого эксперимента состоит не в универсальном превосходстве предложенных методов, а в том, что проекторная нормировка делает экспоненциальный подход работоспособным и конкурентным в широком диапазоне долей наблюдений.

6.4 Sweep по condition number

Особенно важен эксперимент с изменением condition number истинной матрицы. Именно в этом режиме должна проявляться основная проблема исходной двусторонней экспоненциальной схемы. Напомним, что её первый порядок содержит направление

$$GA^T A + AA^T G.$$

Если $A = U\Sigma V^T$, то

$$A^T A = V\Sigma^2 V^T, \quad AA^T = U\Sigma^2 U^T.$$

Следовательно, направление исходного метода масштабируется квадратами сингулярных значений. При высокой обусловленности это приводит к неравномерному обновлению разных сингулярных направлений.




Рис. 5: Зависимость качества восстановления от condition number истинной матрицы.

Эксперимент с condition number подтверждает основную гипотезу работы. При росте обусловленности исходный Exp-Two-Sided показывает существенно более высокую ошибку: например, при condition number 10, 100 и 1000 его full relative error остаётся примерно на уровне 0.89–1.00. Нормированные схемы в тех же режимах дают ошибку примерно 0.53–0.58 и тем самым существенно снижают деградацию, связанную с множителями Σ^2 . При этом Riemannian-GD в некоторых режимах оказывается ещё сильнее, что подчёркивает необходимость сравнения с геометрическими baseline-методами.

Таким образом, именно sweep по condition number является главным экспериментальным подтверждением идеи проекторной нормировки: замена грамовых множителей $A^\top A$ и $AA^\top$ на проекторы P_V и P_U действительно уменьшает плохое спектральное масштабирование исходного экспоненциального шага.

6.5 Rank mismatch

В реальных задачах истинный ранг обычно неизвестен. Поэтому был проведён эксперимент, в котором истинный ранг равен $r_\star = 4$, а обучение проводится с различными значениями ранга r .




Рис. 6: Зависимость качества восстановления от обучающего ранга r при истинном ранге $r_\star = 4$.

Важно, что лучший результат при меньшем ранге не означает, что истинная матрица имеет ранг 2. Лучшее приближение истинной матрицы рангом 2 имеет относительную ошибку около 0.073, а для ранга 4 ошибка лучшего рангового приближения практически равна нулю. Однако в задаче matrix completion матрица восстанавливается не по всем элементам, а по неполным и шумным наблюдениям. Поэтому меньший используемый ранг может выступать как регуляризация и давать меньшую ошибку восстановления при ограниченном числе наблюдений. При завышении ранга возрастает риск подгонки под наблюдаемые элементы, что ухудшает восстановление всей матрицы.

Этот эксперимент показывает, что выбор ранга является отдельной важной задачей и не должен рассматриваться как чисто технический параметр. В практических задачах ранг следует выбирать по validation loss или по дополнительным критериям регуляризации.

6.6 Сравнение нормированных схем

Сравнение Euler-Norm-Two-Sided и Norm-Exp-Two-Sided позволяет понять, какая часть улучшения связана с самим нормированным направлением, а какая — с экспоненциальной формой обновления. Результаты ablation study приведены в таблице 3.

Метод	test loss	full relative error
Norm-Exp-Two-Sided	$3.2 \cdot 10^{-5}$	0.512
Euler-Norm-Two-Sided	$3.5 \cdot 10^{-5}$	0.512
ScaledGD	$3.9 \cdot 10^{-5}$	0.536
Riemannian-GD	$9.8 \cdot 10^{-5}$	0.427
Exp-Two-Sided	$2.39 \cdot 10^{-4}$	0.926

Таблица 3: Ablation study: сравнение исходного и нормированных экспоненциальных методов.




Рис. 7: Ablation study: сравнение сходимости исходной экспоненциальной схемы, нормированной экспоненциальной схемы и эйлеровой нормированной схемы.

Ablation study показывает, что обе нормированные схемы существенно улучшают исходный Exp-Two-Sided как по test loss, так и по full relative error. При этом Euler-Norm-Two-Sided и Norm-Exp-Two-Sided дают близкие результаты. Это подтверждает, что ключевой вклад даёт именно замена грамовых множителей на проекторы. Отличия между эйлеровой и экспоненциальной реализациями в данном запуске меньше, чем разрыв между нормированными схемами и исходной экспоненциальной схемой.

Следует отметить, что Riemannian-GD в этом эксперименте имеет худший test loss, но лучший full relative error. Это показывает, что разные метрики могут по-разному ранжировать методы: оптимизация наблюдаемых элементов не всегда полностью совпадает с качеством восстановления всей матрицы.

6.7 Runtime и масштабируемость

Следующий эксперимент сравнивает время работы методов при изменении размера матрицы. Он не является полноценным benchmark для больших задач, но позволяет оценить стоимость наивных реализаций.




Рис. 8: Сравнение времени работы методов при изменении размера матрицы.

Runtime-эксперимент показывает, что ScaledGD остаётся самым быстрым методом среди рассмотренных, так как работает с низкоранговыми факторами. Norm-Exp-Two-Sided дороже ScaledGD из-за вычисления псевдообратной и экспоненциального действия, но в наивной реализации на размерах до 80×80 оказывается сравнимым с Riemannian-GD и не обязательно хуже SVP. Поэтому главный вычислительный недостаток Norm-Exp-Two-Sided состоит не в полной непрактичности, а в необходимости более эффективной реализации для больших матриц.

7 Обсуждение результатов

Проведённые эксперименты позволяют сделать несколько выводов.

Во-первых, исходный двусторонний экспоненциальный метод действительно страдает от плохого спектрального масштабирования. Теоретически это связано с тем, что его первый порядок содержит матрицы Грама $A^T A$ и AA^T , то есть множители Σ^2 в сингулярных координатах. Экспериментально это особенно заметно в sweep по condition number: Exp-Two-Sided оказывается существенно хуже нормированных схем при росте обусловленности истинной матрицы.

Во-вторых, проекторная нормировка через

$$P_U = AA^+, \quad P_V = A^+A$$

существенно улучшает поведение экспоненциального подхода. Замена

$$A^T A \rightarrow A^+ A = P_V, \quad AA^T \rightarrow AA^+ = P_U$$

удаляет зависимость направления от квадратов сингулярных значений и оставляет только зависимость от текущих левого и правого подпространств.

В-третьих, Euler-Norm-Two-Sided следует рассматривать не как внешний baseline, а как одну из двух предложенных реализаций проекторно-нормированной идеи. Он показывает, что само направление

$$D(A) = GP_V + P_U G$$

является эффективным. Norm-Exp-Two-Sided является более структурной версией той же идеи: она сохраняет ранг без явной SVD-проекции после шага, но требует более дорогих матричных операций.

В-четвёртых, предложенные методы не доминируют над всеми классическими алгоритмами во всех режимах. SVP, Riemannian-GD, Factor-GD и ScaledGD остаются сильными baseline-методами.

Отдельно отметим ограничения подхода. Эйлерова нормированная схема требует SVD-проекции на каждом шаге, как и SVP или простая риманова ретракция. Нормированная экспоненциальная схема сохраняет ранг структурно, но в наивной реализации требует вычисления псевдообратной матрицы и матричных экспонент. Кроме того, наличие Σ^{-1} в A^+ может создавать численную чувствительность при малых сингулярных значениях. Поэтому для практического применения экспоненциальной схемы важны регуляризация псевдообратной, адаптивный выбор шага и более эффективное вычисление действия матричной экспоненты.

8 Заключение

В данной курсовой работе была рассмотрена задача построения методов для низкоранговой матричной оптимизации. Исходной точкой служил экспоненциальный шаг, возникающий из идеи фиктивной многофакторной параметризации. Было показано, что левый односторонний шаг сохраняет ранг и ядро матрицы, а правый односторонний шаг сохраняет ранг и образ матрицы. В обоих случаях одно из сингулярных подпространств оказывается фиксированным, что делает односторонние схемы слишком жёсткими для задач восстановления низкоранговой структуры.

Для устранения этого ограничения была рассмотрена двусторонняя экспоненциальная схема. Она позволяет менять и левое, и правое подпространства, сохраняя ранг за счёт умножения слева и справа на обратимые матрицы. Однако анализ первого порядка показал наличие другого дефекта: направление масштабируется через матрицы Грама $A^T A$ и AA^T , то есть через квадраты сингулярных значений. Это приводит к плохому поведению при высокой обусловленности.

Основным результатом работы является проекторно-нормированное направление

$$D(A) = \nabla L(A)P_V + P_U \nabla L(A), \quad P_U = AA^+, \quad P_V = A^+A.$$

Оно сохраняет зависимость от текущих левого и правого подпространств, но удаляет нежелательное масштабирование через Σ^2 . На основе этого направления были построены две схемы:

1. Euler-Norm-Two-Sided — эйлерова проекторная схема;

2. Norm-Exp-Two-Sided — экспоненциальная ранго-сохраняющая схема.

Численные эксперименты показывают, что обе схемы существенно улучшают поведение исходного Exp-Two-Sided. Особенно важным является эксперимент с изменением condition number, где нормированные методы значительно уменьшают ошибку по сравнению со старой двусторонней экспоненциальной схемой. Multi-seed проверка показывает, что предложенные методы входят в верхнюю группу алгоритмов, хотя не превосходят все baseline-методы во всех режимах.

Таким образом, предложенный подход не следует рассматривать как окончательную замену всем существующим алгоритмам низкоранговой оптимизации. Более точная интерпретация результата состоит в следующем: найдено проекторно-нормированное направление, которое исправляет структурный дефект исходных экспоненциальных схем и даёт две практически интересные реализации — проекторную и экспоненциальную.

8.1 Планы на будущее

В дальнейшем планируется:

- реализовать более эффективное вычисление экспоненциального действия без построения полных матричных экспонент;
- исследовать выбор ранга по validation loss;
- добавить адаптивный line search для выбора шага η ;
- исследовать регуляризованную псевдообратную матрицу при малых сингулярных значениях;
- получить теоретические оценки сходимости для нормированного потока; и alternating minimization;
- отдельно исследовать, в каких режимах Euler-Norm-Two-Sided превосходит классический SVP и ScaledGD.

Список литературы

- [1] B. Vandereycken, Low-rank matrix completion by Riemannian optimization, SIAM Journal on Optimization, 23(2), 1214–1236, 2013.
- [2] P. Jain, R. Meka, I. S. Dhillon, Guaranteed rank minimization via singular value projection, Advances in Neural Information Processing Systems, 23, 2010.
- [3] R. Mazumder, T. Hastie, R. Tibshirani, Spectral regularization algorithms for learning large incomplete matrices, Journal of Machine Learning Research, 11(80), 2287–2322, 2010.
- [4] T. Tong, C. Ma, Y. Chi, Accelerating ill-conditioned low-rank matrix estimation via scaled gradient descent, Journal of Machine Learning Research, 22(150), 1–63, 2021.